

Detection de la retinopathie diabetique par Deep Learning

Guide pedagogique complet : la maladie, les stades cliniques,
le fonctionnement du modele, l'entrainement et les metriques

Projet APTOS 2019 | ResNet34 | PyTorch
Document genere automatiquement

Sommaire

1. Vue d'ensemble du projet
2. La maladie : la retinopathie diabetique
3. Les 5 stades et leurs criteres cliniques
4. Le pipeline du projet (vue globale)
5. Le pretraitement des images (OpenCV)
6. Le modele : Deep Learning et CNN
7. ResNet34 et le transfer learning
8. Train / Validation / Test
9. Comment le modele apprend
10. Les metriques d'evaluation
11. Les resultats obtenus
12. Grad-CAM : l'explicabilite
13. Glossaire complet des acronymes
14. Les commandes du projet

1. Vue d'ensemble du projet

Ce projet construit un système d'**intelligence artificielle** capable de regarder une photographie du fond de l'oeil (une **retinographie**) et de dire automatiquement à quel **stade de gravité** se trouve la retinopathie diabétique, sur une échelle de 0 (sain) à 4 (le plus grave).

Le système apprend tout seul à partir de **2930 images** déjà diagnostiquées par des médecins (le dataset public APTOS 2019). Une fois entraîné, il peut diagnostiquer une nouvelle image en une fraction de seconde.

Idee cle : on ne programme pas de règles à la main ("si tache rouge alors..."). Le modèle **decouvre lui-même** les signes de la maladie en observant des milliers d'exemples. C'est le principe du **deep learning**.

2. La maladie : la retinopathie diabétique

La **retinopathie diabétique** est une complication du diabète qui abîme les petits vaisseaux sanguins de la **retine** (le fond de l'oeil). C'est l'une des premières causes de cécité chez l'adulte. Plus elle est détectée tôt, mieux elle se soigne, d'où l'intérêt d'un dépistage automatique.

Les lésions que l'on cherche sur l'image

Lesion	Description
Micro-anevrismes	Minuscules dilatations des capillaires, premiers signes (petits points rouges).
Hémorragies	Fuites de sang dans la rétine (taches rouges plus grandes).
Exsudats	Dépôts de graisses/proteines (taches jaunes brillantes).
AMIR / IRMA	Anomalies microvasculaires intra-rétiniennes (vaisseaux anormaux).
Neovascularisation	Croissance de nouveaux vaisseaux anormaux et fragiles (stade le plus grave).

3. Les 5 stades et leurs critères cliniques

La classification suit l'**échelle internationale de sévérité** de la retinopathie diabétique. Les stades 0 à 3 sont dits **non proliférants** (NPDR), le stade 4 est **proliférant** (PDR).

Stade	Nom	Critère clinique
0	Pas de retinopathie	Aucune anomalie visible. Rétine saine.
1	Légère (Mild NPDR)	Micro-anevrismes uniquement. Tout premier stade.
2	Modérée (Moderate NPDR)	Plus que de simples micro-anevrismes (hémorragies, exsudats...) mais sans atteindre le stade sévère.
3	Sévère (Severe NPDR)	Règle 4-2-1 : hémorragies importantes dans les 4 quadrants, OU dilatation veineuse dans 2 quadrants, OU AMIR marquées dans 1 quadrant. Pas encore de neovaisseaux.
4	Proliférante (PDR)	Neovascularisation (nouveaux vaisseaux anormaux) et/ou hémorragie du vitre. Stade le plus grave, risque de cécité.

A retenir : les stades sont **ordonnes** ($0 < 1 < 2 < 3 < 4$) et les frontieres entre stades voisins sont floues, meme pour un ophtalmologue. C'est pour cela qu'on utilise une metrique speciale, le **kappa quadratique** (chapitre 10), qui pardonne les erreurs entre stades proches.

4. Le pipeline du projet (vue globale)

Voici les grandes étapes, de l'image brute au diagnostic :

Image retine

- |
- v 1. PRETRAITEMENT (OpenCV : crop + CLAHE + resize)
- |
- v 2. MODELE CNN (ResNet34, transfer learning)
- |
- v 3. SORTIE : 5 probabilités (un score par stade)
- |
- v 4. DIAGNOSTIC : le stade le plus probable

Les étapes 1 à 4 servent à **predire**. Pour **apprendre**, on ajoute une boucle de correction (chapitre 9).

5. Le pretraitement des images (OpenCV)

Avant d'entrer dans le modèle, chaque image est nettoyée et standardisée avec la bibliothèque **OpenCV**. Quatre opérations :

Etape	Role
Crop circulaire	Enleve les bandes noires autour du disque retinien, recadre sur l'oeil.
CLAHE	Rehaussement de contraste local : fait ressortir les vaisseaux et lésions sans cramer l'image.
Redimensionnement	Toutes les images ramenées à 224x224 pixels (taille attendue par ResNet).
Normalisation	Les couleurs sont recalibrées avec les statistiques d'ImageNet (moyenne/ecart-type), car le modèle pré-entraîne les attend.

Pourquoi standardiser ? Les photos viennent d'appareils et de conditions d'éclairage différents. En les uniformisant, on aide le modèle à se concentrer sur la **maladie** plutôt que sur les différences de matériel.

6. Le modèle : Deep Learning et CNN

Intelligence artificielle, machine learning, deep learning

Ce sont des poupées russes :

- **IA** : le grand domaine (faire faire à une machine des tâches "intelligentes").
- **Machine Learning (ML)** : la machine apprend à partir de données au lieu d'être programmée.
- **Deep Learning (DL)** : du ML avec des réseaux de neurones **profonds** (beaucoup de couches).

	Machine Learning classique	Deep Learning
Données	Tableaux de chiffres	Images, sons, textes
Qui choisit les variables ?	L'humain, à la main	Le réseau, tout seul
Sur une image	Mauvais	Excellent

Le CNN et la convolution

Pour les images, on utilise un **CNN** (Convolutional Neural Network = reseau de neurones convolutif). Son operation cle est la **convolution** : de petits **filtres** glissent sur l'image pour detecter des motifs. En empilant les couches, le reseau detecte des motifs de plus en plus complexes :

```
Couche 1    -> bords, coins, couleurs
Couche 2    -> textures, courbes
Couche 3    -> vaisseaux, taches
...
Couche finale -> lesions, diagnostic (stade 0 a 4)
```

7. ResNet34 et le transfer learning

ResNet34 est l'architecture de CNN utilisee ici. "34" = le nombre de couches. "ResNet" = *Residual Network* (reseau residuel).

Les connexions residuelles (skip connections)

L'innovation de ResNet : des **raccourcis** qui sautent par-dessus des couches. Au lieu d'apprendre toute la transformation, chaque bloc apprend juste la **correction a ajouter**. Resultat : on peut construire des reseaux tres profonds sans qu'ils "se cassent" a l'entrainement.

Le transfer learning

On ne part pas de zero : on prend un ResNet34 **deja entraine** sur ImageNet (1,2 million d'images variees). Il sait deja reconnaitre formes et textures ; on le **specialise** ensuite sur les retines. C'est pour cela qu'on a obtenu un excellent score des la 1ere epoque.

Analogie : plutot que d'apprendre a un enfant a voir depuis zero, on prend un adulte qui sait deja observer le monde, et on lui apprend seulement une nouvelle specialite (lire des retines).

8. Train / Validation / Test

Les 2930 images sont decoupees en **trois ensembles separees**. C'est fondamental pour mesurer honnetement la performance.

Ensemble	Part	Nb images	Role
Train (entrainement)	70%	2051	Le modele apprend dessus : il voit ces images et corrige ses erreurs.
Validation	15%	439	Controle pendant l'entrainement : verifie qu'il generalise et choisit le meilleur modele.
Test	15%	440	Examen final, sur des images JAMAIS vues. Mesure honnete de la vraie performance.

Pourquoi separer ?

Si on testait le modele sur les images d'entrainement, il pourrait avoir simplement **memorise** les reponses (comme un eleve qui apprend le corrige par coeur). Le jeu de **test** verifie qu'il a vraiment compris, sur de l'inedit.

Le surapprentissage (overfitting)

Quand un modele devient excellent sur le train mais stagne (ou empire) sur la validation, il **surapprend** : il memorise au lieu de generaliser. On le repere quand l'erreur de validation remonte alors que celle d'entrainement continue de baisser. C'est pour cela qu'on sauvegarde le **meilleur modele selon la validation**, pas le dernier.

9. Comment le modele apprend

L'apprentissage est une boucle repetee des milliers de fois. Quelques definitions d'abord :

- **Epoque (epoch)** : un passage complet sur toutes les images d'entrainement. Ici : 15 epoques.
- **Batch** : un petit paquet d'images traitees ensemble. Ici : 16 images par batch ($2051 / 16 = 129$ batches par epoque).

Pour chaque batch, 5 etapes :

Eta pe	Nom	Ce qui se passe
1	Forward (propagation avant)	Les images traversent le reseau, qui predit un stade.
2	Loss (perte)	On mesure l'erreur : ecart entre prediction et vraie reponse.
3	Backward (retropropagation)	On calcule comment chaque parametre a contribue a l'erreur.
4	Step (optimiseur)	On ajuste legerement chaque parametre pour reduire l'erreur.
5	Repeter	On passe au batch suivant, puis a l'epoque suivante.

Les ingredients techniques

Element	Choix dans le projet	Role
Fonction de perte	CrossEntropy ponderee	Mesure l'erreur ; ponderee pour gerer le desequilibre des stades.
Optimiseur	AdamW	Decide comment ajuster les parametres (descente de gradient ameliee).
Learning rate	0.0001	Taille des pas de correction.
AMP	Mixed precision	Calculs en 16 bits : economise la memoire GPU et accelere.

Analogie de la descente : l'erreur est une montagne dans le brouillard. A chaque pas, on sent la pente (le **gradient**) et on avance d'un petit pas (le **learning rate**) vers le bas, jusqu'a atteindre la vallee (erreur minimale).

10. Les metriques d'evaluation

Comment juger si le modele est bon ? Plusieurs mesures complementaires :


Metrique	Definition
Accuracy (exactitude)	Pourcentage de predictions exactes. Simple, mais trompeuse si les classes sont desequilibrees.
Precision	Parmi les cas predits "stade X", combien le sont vraiment. (Eviter les fausses alertes.)
Recall (rappel)	Parmi les vrais "stade X", combien sont retrouves. (Eviter les oublis.)
F1-score	Moyenne equilibree de la precision et du rappel.
Support	Nombre d'images reelles de chaque stade dans le test.
Kappa quadratique	Metrique OFFICIELLE d'APTOS. Mesure l'accord en penalisant fortement les grosses erreurs et peu les erreurs entre stades voisins.

Pourquoi le kappa quadratique ?

Comme les stades sont ordonnes, confondre le stade 2 et le 3 (voisins) est peu grave, alors que confondre 0 et 4 serait dramatique. Le **quadratic weighted kappa** tient compte de cette **distance** entre stades. Echelle : 0 = hasard, 1 = parfait ; 0,8 a 0,9 = tres bon.

La matrice de confusion

Elle croise la **verite** (lignes) et la **prediction** (colonnes). La diagonale = les bonnes reponses. Les cases hors diagonale = les confusions. Voici celle obtenue sur le jeu de test :



Matrice de confusion sur les 440 images de test.

11. Les resultats obtenus

Après 15 epoques d'entrainement (ResNet34) :

Mesure	Valeur
Accuracy (test)	0,814
Kappa quadratique (test)	0,889 (tres bon)
Kappa (validation)	0,893

Le kappa de test (0,889) est quasi identique a celui de validation (0,893) : le modele **generalise bien**, sans tricherie cachee.


Performance detaillee par stade

Stade	Precision	Recall	F1	Support
0 - Pas de retinopathie	0,986	0,972	0,979	215
1 - Legere	0,528	0,622	0,571	45
2 - Moderee	0,757	0,713	0,734	122
3 - Severe	0,500	0,478	0,489	23
4 - Proliferante	0,605	0,657	0,630	35

Lecture : le stade 0 (sain) est quasi parfait. Les stades 1 et 3 sont les plus durs car ils ont peu d'exemples ET ce sont des stades intermediaires aux frontieres floues. Surtout, le modele ne fait **jamais** d'erreur grave (confondre sain et tres grave) : ses erreurs restent sur des stades voisins.

12. Grad-CAM : l'explicabilite

Un reseau de neurones est souvent une **boite noire**. Le **Grad-CAM** (Gradient-weighted Class Activation Mapping) l'ouvre : il produit une **carte de chaleur** montrant les zones de l'image qui ont le plus influence la decision. Rouge = zone regardee, bleu = zone ignoree.



Grad-CAM sur un cas avance (predit stade 3 - severe) : le modele se concentre sur la zone centrale de la retine, la ou se trouvent les lesions.

Pourquoi c'est important : un medecin peut **verifier** que le modele regarde des zones medicalement pertinentes, et non un artefact. C'est essentiel pour la confiance en IA medicale.

13. Glossaire complet des acronymes

Sigle	Signification
IA	Intelligence Artificielle.
ML	Machine Learning : apprentissage automatique a partir de donnees.
DL	Deep Learning : ML avec reseaux de neurones profonds.
CNN	Convolutional Neural Network : reseau de neurones convolutif, specialise pour les images.
ResNet	Residual Network : architecture CNN avec connexions residuelles (raccourcis).
ReLU	Rectified Linear Unit : fonction d'activation courante (garde les valeurs positives).
APTOS	Asia Pacific Tele-Ophthalmology Society : organisateur du dataset/competition.
NPDR	Non-Proliferative Diabetic Retinopathy : stades 0 a 3.
PDR	Proliferative Diabetic Retinopathy : stade 4 (avec neovaisseaux).
DMLA	Degenerescence Maculaire Liee a l'Age (autre maladie de la retine).
AMIR / IRMA	Anomalies Microvasculaires Intra-Retiniennes (Intraretinal Microvascular Abnormalities).
CLAHE	Contrast Limited Adaptive Histogram Equalization : rehaussement de contraste local.
RGB	Red-Green-Blue : codage couleur d'une image (3 canaux).
LAB	Espace colorimetrique Luminance + 2 axes couleur (utilise par CLAHE).
Kappa	Quadratic Weighted Kappa : metrique d'accord penalisant selon la distance entre classes.
GPU	Graphics Processing Unit : carte graphique, ideale pour le calcul parallele du DL.
CUDA	Plateforme NVIDIA permettant d'utiliser le GPU pour le calcul.
VRAM	Video RAM : memoire du GPU (ici 4 Go).
AMP	Automatic Mixed Precision : calculs en 16 bits pour economiser memoire et temps.
AdamW	Optimiseur (variante d'Adam avec weight decay) : ajuste les parametres.
LR	Learning Rate : taille des pas de correction pendant l'apprentissage.
Epoch	Epoque : un passage complet sur toutes les donnees d'entrainement.
Batch	Lot d'images traitees ensemble a chaque etape.
Loss	Fonction de perte : mesure chiffree de l'erreur du modele.
Grad-CAM	Gradient-weighted Class Activation Mapping : carte de chaleur d'explicabilite.
CSV	Comma-Separated Values : fichier tableur texte (ici les labels).
PNG	Format d'image sans perte (les retinographies).
venv	Virtual environment : environnement Python isole pour le projet.

API	Application Programming Interface : interface pour appeler un service par programme.
------------	--

14. Les commandes du projet

Toutes les commandes se lancent depuis le dossier du projet, via le lanceur `run.ps1` qui regle l'environnement automatiquement.

Commande	Role
<code>run.ps1 src.download_data</code>	Telecharge les donnees APTOS.
<code>run.ps1 src.preprocess <image></code>	Montre le pretraitement avant/apres.
<code>run.ps1 src.train</code>	Entraîne le modele.
<code>run.ps1 src.evaluate</code>	Evalue sur le test (kappa + matrice).
<code>run.ps1 src.predict --image </code>	Predit le stade d'une image.
<code>run.ps1 src.gradcam --image </code>	Carte de chaleur Grad-CAM.

Options de l'entrainement

```
run.ps1 src.train --epochs 15 --model resnet34 --batch-size 16 --lr 0.0001
```

Fin du document. Projet APTOS - detection de la retinopathie diabetique par deep learning.